

✓ Рубежный контроль №1 - Отчёт

Имя - Фон Маунг Хтве

Группа - ИУ5И-23М

Номер в списке - 2

Номер варианта - 17

Номер варианта - 37

Тема - Методы обработки данных (Methods of Data Processing)

О наборе данных

- **Название набора данных** - California Housing dataset
- **Источник** - модуль datasets библиотеки scikit-learn
- **Количество строк** - 20 640
- **Количество столбцов** - 8 (признаки) + 1 (целевая переменная)
- **Описание столбцов**
 - MedInc - медианный доход в районе
 - HouseAge - медианный возраст дома
 - AveRooms - среднее количество комнат
 - AveBedrms - среднее количество спален
 - Population - численность населения
 - AveOccup - средняя занятость домохозяйства
 - Latitude - широта
 - Longitude - долгота
 - **Целевая переменная (y)** - MedHouseVal (медианная стоимость дома)

✓ Задача №37: Отбор признаков и дополнительный график Vохplot

Условие задачи:

Используя класс `SelectPercentile` с параметром `percentile=5` и метод отбора на основе взаимной информации (`mutual_info_regression`), провести отбор наиболее информативных признаков.

Дополнительное требование:

Построить график "Ящик с усами" (boxplot) для произвольной числовой колонки данных.

Выполнение:

1. Отбор признаков

- Берутся все 8 исходных признаков набора данных California Housing.
- Для каждого признака вычисляется взаимная информация с целевой переменной (`MedHouseVal`).
- Отбираются 5% лучших признаков (от 8 признаков $5\% = 0.4 \rightarrow$ округление до 1 признака).

2. Результат отбора

- По значениям взаимной информации, наибольший вклад даёт географический признак `Longitude` (долгота).
- Это связано с тем, что цены на жильё в Калифорнии сильно зависят от расположения (побережье дороже).
- `MedInc` (медианный доход) находится на втором месте.

3. Vохplot (ящик с усами)

- Для колонки `MedInc` строится boxplot.
- График показывает медиану, межквартильный размах, "усы" и выбросы.
- Визуально подтверждается асимметрия распределения, что оправдывает применение преобразования Йео-Джонсона в задаче №17.

Важно:

Если требуется принудительно отобрать `MedInc`, необходимо увеличить `percentile` (например, до 20–30%). Однако строго по условию (5%) отбирается `Longitude` — это не ошибка, а особенность данных.

```
# Импорт необходимых библиотек (PyTorch + sklearn)
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import torch
import torch.nn as nn
import torch.optim as optim
from torch.utils.data import DataLoader, TensorDataset
from sklearn.datasets import fetch_california_housing
from sklearn.preprocessing import PowerTransformer
from sklearn.feature_selection import SelectPercentile, mutual_info_regression
```

```
import warnings
warnings.filterwarnings('ignore')

print("Библиотеки успешно загружены (PyTorch version)")
print("Версия PyTorch:", torch.__version__)
```

```
Библиотеки успешно загружены (PyTorch version)
Версия PyTorch: 2.10.0+cpu
```

```
# Загрузка набора данных California Housing (с запасным вариантом)
try:
    housing = fetch_california_housing()
    df = pd.DataFrame(housing.data, columns=housing.feature_names)
    y = housing.target
    print("Данные загружены из sklearn.datasets")
except Exception as e:
    print(f"Ошибка: {e}")
    print("Создаём синтетические данные для демонстрации...")
    np.random.seed(42)
    n_samples = 1000
    df = pd.DataFrame({
        'MedInc': np.random.exponential(5, n_samples),
        'HouseAge': np.random.randint(1, 52, n_samples),
        'AveRooms': np.random.uniform(3, 10, n_samples),
```

```

'AveBedrms': np.random.uniform(1, 3, n_samples),
'Population': np.random.randint(100, 5000, n_samples),
'AveOccup': np.random.uniform(1, 5, n_samples),
'Latitude': np.random.uniform(32, 42, n_samples),
'Longitude': np.random.uniform(-124, -114, n_samples)
})
y = df['MedInc'] * 0.5 + df['AveRooms'] * 0.3 + np.random.normal(0, 0.5, n_samples)
print("Используются синтетические данные")

print("\nПервые 5 строк набора данных:")
print(df.head())
print("\nФорма (размерность) набора данных:", df.shape)

```

Данные загружены из sklearn.datasets

Первые 5 строк набора данных:

	MedInc	HouseAge	AveRooms	AveBedrms	Population	AveOccup	Latitude	Longitude
0	8.3252	41.0	6.984127	1.023810	322.0	2.555556	37.88	-122.23
1	8.3014	21.0	6.238137	0.971880	2401.0	2.109842	37.86	-122.22
2	7.2574	52.0	8.288136	1.073446	496.0	2.802260	37.85	-122.24
3	5.6431	52.0	5.817352	1.073059	558.0	2.547945	37.85	-122.25
4	3.8462	52.0	6.281853	1.081081	565.0	2.181467	37.85	-122.25

Longitude

```

0    -122.23
1    -122.22
2    -122.24
3    -122.25
4    -122.25

```

Форма (размерность) набора данных: (20640, 8)

```

# Задача №17: Преобразование Йео-Джонсона
column_name = 'MedInc'
original_data = df[column_name].copy()

yj_transformer = PowerTransformer(method='yeo-johnson')
transformed_data = yj_transformer.fit_transform(df[[column_name]])
df['MedInc_YeoJohnson'] = transformed_data

print("Исходные данные (первые 10):")
print(original_data.head(10))
print("\nПосле преобразования Йео-Джонсона (первые 10):")
print(df['MedInc_YeoJohnson'].head(10))

# Визуализация
fig, axes = plt.subplots(1, 2, figsize=(14, 5))
sns.histplot(original_data, kde=True, ax=axes[0], color='blue')
axes[0].set_title(f'Исходное распределение {column_name}')
sns.histplot(df['MedInc_YeoJohnson'], kde=True, ax=axes[1], color='green')
axes[1].set_title(f'После преобразования Йео-Джонсона ({column_name})')
plt.tight_layout()
plt.show()

```

Исходные данные (первые 10):


```
0 8.3252
1 8.3014
2 7.2574
3 5.6431
4 3.8462
5 4.0368
6 3.6591
7 3.1200
8 2.0804
9 3.6912
```

Name: MedInc, dtype: float64

После преобразования Йео-Джонсона (первые 10):

```
0 1.903289
1 1.897081
2 1.604361
3 1.051321
4 0.205878
5 0.312151
6 0.096567
7 -0.250386
8 -1.105344
9 0.115691
```

Name: MedInc_YeoJohnson, dtype: float64



```
# Задача №37: Отбор признаков (5%) + Boxplot
X = df[housing.feature_names] if 'housing' in dir() else df[['MedInc', 'HouseAge', 'AveRooms', 'AveBedrms',
'Population', 'AveOccup', 'Latitude', 'Longitude']]

selector = SelectPercentile(score_func=mutual_info_regression, percentile=5)
selector.fit(X, y)

selected_mask = selector.get_support()
selected_features = X.columns[selected_mask]
mi_scores = selector.scores_

print("=" * 60)
print("РЕЗУЛЬТАТ ОТБОРА ПРИЗНАКОВ (ЗАДАЧА №37)")
print("=" * 60)
print("Общее количество признаков:", X.shape[1])
print("Количество отобранных признаков (5%):", selected_mask.sum())
print("\nОтобранные признаки (top 5%):")
for feat in selected_features:
    print(f"  ✓ {feat}")

scores_df = pd.DataFrame({
    'Feature': X.columns,
    'MI_Score': mi_scores,
    'Selected': selected_mask
}).sort_values('MI_Score', ascending=False)
print("\nОценки взаимной информации:")
print(scores_df)

# Boxplot для группы ИУ5И-23М
plt.figure(figsize=(6, 5))
sns.boxplot(y=df['MedInc'], color='lightblue')
plt.title('Ящик с усами (Boxplot) для признака MedInc', fontsize=12)
plt.xlabel('Медицинский доход (MedInc)')
```

```
plt.grid(axis='y', linestyle='--', alpha=0.7)
plt.show()
```

=====

РЕЗУЛЬТАТ ОТБОРА ПРИЗНАКОВ (ЗАДАЧА №37)

=====

Общее количество признаков: 8

Количество отобранных признаков (5%): 1


Отобранные признаки (top 5%):

✓ Longitude

Оценки взаимной информации:

	Feature	MI_Score	Selected
7	Longitude	0.400090	True
0	MedInc	0.387967	False
6	Latitude	0.368843	False
2	AveRooms	0.103548	False
5	AveOccup	0.072629	False
1	HouseAge	0.032200	False
3	AveBedrms	0.024122	False
4	Population	0.021215	False

Ящик с усами (Boxplot) для признака MedInc



Double-click (or enter) to edit

✓ Заключение (Conclusion)

1. **Преобразование Йео-Джонсона** - Исходный столбец MedInc имеет правостороннее (right-skewed) распределение. После преобразования Йео-Джонсона распределение становится ближе к нормальному распределению (normal distribution).
2. **Отбор признаков** - Согласно взаимной информации (Mutual Information), наибольшую важность для прогнозирования стоимости дома имеет признак Longitude (долгота). В соответствии с заданным порогом 5% был выбран только один признак - Longitude.
3. **Boxplot (ящик с усами)** - Для группы ИУ5И-23М построен boxplot для признака MedInc. График показывает медиану, межквартильный размах и выбросы, подтверждая асимметрию исходного распределения.

```
# PDF ပြောင်းရန် လိုအပ်သော package များ install လုပ်ခြင်း
!pip install nbconvert -q
!apt-get install texlive-xetex texlive-fonts-recommended texlive-plain-generic pandoc -qq

# လက်ရှိ notebook ကို PDF အဖြစ် ပြောင်းခြင်း
!jupyter nbconvert --to pdf /content/*.ipynb --output-dir=/content/

# PDF ဖိုင်၏ အမှန်တကယ်အမည်ကို ရှာဖွေခြင်း
import os
import glob

# content folder ထဲက .pdf ဖိုင်များကို ရှာပါ
pdf_files = glob.glob('/content/*.pdf')
```

```

if pdf_files:
    # ပထမဆုံးတွေ့သော PDF ဖိုင်ကို ရွေးပါ
    pdf_path = pdf_files[0]
    print(f"PDF ဖိုင်တွေ့ရှိပါသည်: {pdf_path}")

    # PDF ဖိုင်ကို ဒေါင်းလုဒ်လုပ်ခြင်း
    from google.colab import files
    files.download(pdf_path)
else:
    print("PDF ဖိုင် မတွေ့ပါ။ nbconvert အလုပ်မလုပ်နိုင်သေးပါ။")
    print("ကျေးဇူးပြု၍ အောက်ပါ HTML နည်းလမ်းကို သုံးပါ။")

```

```

    See the usage documentation
    (https://nbconvert.readthedocs.io/en/latest/usage.html#reveal-js-html-slideshow)
    for more details.
    Default: ''
    Equivalent to: [--SlidesExporter.reveal_url_prefix]
--nbformat=<Enum>
    The nbformat version to write.
    Use this to downgrade notebooks.
    Choices: any of [1, 2, 3, 4]
    Default: 4
    Equivalent to: [--NotebookExporter.nbformat_version]

Examples
-----

```