

✓ Рубежный контроль №1 - Отчёт

Имя - Фон Маунг Хтве

Группа - ИУ5И-23М

Номер в списке - 2

Номер варианта - 17

Номер варианта - 37

Тема - Методы обработки данных (Methods of Data Processing)

О наборе данных

- **Название набора данных** - California Housing dataset
- **Источник** - модуль datasets библиотеки scikit-learn
- **Количество строк** - 20 640
- **Количество столбцов** - 8 (признаки) + 1 (целевая переменная)
- **Описание столбцов**
 - MedInc - медианный доход в районе
 - HouseAge - медианный возраст дома
 - AveRooms - среднее количество комнат
 - AveBedrms - среднее количество спален
 - Population - численность населения
 - AveOccup - средняя занятость домохозяйства
 - Latitude - широта
 - Longitude - долгота
 - **Целевая переменная (y)** - MedHouseVal (медианная стоимость дома)

✓ Отбор признаков и дополнительный график Boxplot

Условие задачи:

Используя класс `SelectPercentile` с параметром `percentile=5` и метод отбора на основе взаимной информации (`mutual_info_regression`), провести отбор наиболее информативных признаков.

Дополнительное требование:

Построить график "Ящик с усами" (boxplot) для произвольной числовой колонки

данных.

Выполнение:

1. Отбор признаков

- Берутся все 8 исходных признаков набора данных California Housing.
- Для каждого признака вычисляется взаимная информация с целевой переменной (`MedHouseVal`).
- Отбираются 5% лучших признаков (от 8 признаков $5\% = 0.4 \rightarrow$ округление до 1 признака).

2. Результат отбора

- По значениям взаимной информации, наибольший вклад даёт географический признак `Longitude` (долгота).
- Это связано с тем, что цены на жильё в Калифорнии сильно зависят от расположения (побережье дороже).
- `MedInc` (медианный доход) находится на втором месте.

3. Boxplot (ящик с усами)

- Для колонки `MedInc` строится boxplot.
- График показывает медиану, межквартильный размах, "усы" и выбросы.
- Визуально подтверждается асимметрия распределения, что оправдывает применение преобразования Йео-Джонсона в задаче №17.

Важно:

Если требуется принудительно отобрать `MedInc`, необходимо увеличить `percentile` (например, до 20–30%). Однако строго по условию (5%) отбирается `Longitude` — это не ошибка, а особенность данных.

```
# Импорт необходимых библиотек (PyTorch + sklearn)
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import torch
import torch.nn as nn
import torch.optim as optim
from torch.utils.data import DataLoader, TensorDataset
from sklearn.datasets import fetch_california_housing
from sklearn.preprocessing import PowerTransformer
from sklearn.feature_selection import SelectPercentile, mutual_info_regression

import warnings
warnings.filterwarnings('ignore')
```

```
print("Библиотеки успешно загружены (PyTorch version)")
print("Версия PyTorch:", torch.__version__)
```

```
Библиотеки успешно загружены (PyTorch version)
Версия PyTorch: 2.10.0+cpu
```

```
# Загрузка набора данных California Housing (с запасным вариантом)
try:
    housing = fetch_california_housing()
    df = pd.DataFrame(housing.data, columns=housing.feature_names)
    y = housing.target
    print("Данные загружены из sklearn.datasets")
except Exception as e:
    print(f"Ошибка: {e}")
    print("Создаём синтетические данные для демонстрации...")
    np.random.seed(42)
    n_samples = 1000
    df = pd.DataFrame({
        'MedInc': np.random.exponential(5, n_samples),
        'HouseAge': np.random.randint(1, 52, n_samples),
        'AveRooms': np.random.uniform(3, 10, n_samples),
        'AveBedrms': np.random.uniform(1, 3, n_samples),
        'Population': np.random.randint(100, 5000, n_samples),
        'AveOccup': np.random.uniform(1, 5, n_samples),
        'Latitude': np.random.uniform(32, 42, n_samples),
        'Longitude': np.random.uniform(-124, -114, n_samples)
    })
    y = df['MedInc'] * 0.5 + df['AveRooms'] * 0.3 + np.random.normal(0, 0.5, n_samples)
    print("Используются синтетические данные")

print("\nПервые 5 строк набора данных:")
print(df.head())
print("\nФорма (размерность) набора данных:", df.shape)
```

Данные загружены из sklearn.datasets

Первые 5 строк набора данных:

	MedInc	HouseAge	AveRooms	AveBedrms	Population	AveOccup	Latitude	\
0	8.3252	41.0	6.984127	1.023810	322.0	2.555556	37.88	
1	8.3014	21.0	6.238137	0.971880	2401.0	2.109842	37.86	
2	7.2574	52.0	8.288136	1.073446	496.0	2.802260	37.85	
3	5.6431	52.0	5.817352	1.073059	558.0	2.547945	37.85	
4	3.8462	52.0	6.281853	1.081081	565.0	2.181467	37.85	

Longitude

0	-122.23
1	-122.22
2	-122.24
3	-122.25
4	-122.25

Форма (размерность) набора данных: (20640, 8)

```
# Задача №17: Преобразование Йео-Джонсона
column_name = 'MedInc'
original_data = df[column_name].copy()

yj_transformer = PowerTransformer(method='yeo-johnson')
transformed_data = yj_transformer.fit_transform(df[[column_name]])
df['MedInc_YeoJohnson'] = transformed_data

print("Исходные данные (первые 10):")
print(original_data.head(10))
print("\nПосле преобразования Йео-Джонсона (первые 10):")
print(df['MedInc_YeoJohnson'].head(10))

# Визуализация
fig, axes = plt.subplots(1, 2, figsize=(14, 5))
sns.histplot(original_data, kde=True, ax=axes[0], color='blue')
axes[0].set_title(f'Исходное распределение {column_name}')
sns.histplot(df['MedInc_YeoJohnson'], kde=True, ax=axes[1], color='green')
axes[1].set_title(f'После преобразования Йео-Джонсона ({column_name})')
plt.tight_layout()
plt.show()
```

Исходные данные (первые 10):


```
0    8.3252
1    8.3014
2    7.2574
3    5.6431
4    3.8462
5    4.0368
6    3.6591
7    3.1200
8    2.0804
9    3.6912
```

Name: MedInc, dtype: float64

После преобразования Йео-Джонсона (первые 10):

```
0    1.903289
1    1.897081
2    1.604361
3    1.051321
4    0.205878
5    0.312151
6    0.096567
7   -0.250386
8   -1.105344
9    0.115691
```

Name: MedInc_YeoJohnson, dtype: float64



Задача №37: Отбор признаков (5%) + Boxplot

```
X = df[housing.feature_names] if 'housing' in dir() else df[['MedInc', 'HouseAge',
                                                             'Population', 'Av
```

```
selector = SelectPercentile(score_func=mutual_info_regression, percentile=5)
selector.fit(X, y)
```

```
selected_mask = selector.get_support()
selected_features = X.columns[selected_mask]
mi_scores = selector.scores_

print("=" * 60)
print("РЕЗУЛЬТАТ ОТБОРА ПРИЗНАКОВ (ЗАДАЧА №37)")
print("=" * 60)
print("Общее количество признаков:", X.shape[1])
print("Количество отобранных признаков (5%):", selected_mask.sum())
print("\nОтобранные признаки (top 5%):")
for feat in selected_features:
    print(f"  ✓ {feat}")

scores_df = pd.DataFrame({
    'Feature': X.columns,
    'MI_Score': mi_scores,
    'Selected': selected_mask
}).sort_values('MI_Score', ascending=False)
print("\nОценки взаимной информации:")
print(scores_df)

# Boxplot для группы ИУ5И-23М
plt.figure(figsize=(6, 5))
sns.boxplot(y=df['MedInc'], color='lightblue')
plt.title('Ящик с усами (Boxplot) для признака MedInc', fontsize=12)
plt.ylabel('Медианный доход (MedInc)')
plt.grid(axis='y', linestyle='--', alpha=0.7)
plt.show()
```

```
=====
РЕЗУЛЬТАТ ОТБОРА ПРИЗНАКОВ (ЗАДАЧА №37)
=====
Общее количество признаков: 8
Количество отобранных признаков (5%): 1

Отобранные признаки (top 5%):
✓ Longitude

Оценки взаимной информации:
   Feature  MI_Score  Selected
7  Longitude  0.401609    True
0    MedInc  0.387563    False
6  Latitude  0.369918    False
2  AveRooms  0.103414    False
5  AveOccup  0.073037    False
1  HouseAge  0.033308    False
3  AveBedrms 0.024130    False
4  Population 0.021239    False
```

Double-click (or enter) to edit this title (Boxplot) для признака MedInc

Заключение (Conclusion)

- Преобразование Йео-Джонсона** - Исходный столбец MedInc имеет правостороннее (right-skewed) распределение. После преобразования Йео-Джонсона распределение становится ближе к нормальному распределению (normal distribution).
- Отбор признаков** - Согласно взаимной информации (Mutual Information), наибольшую важность для прогнозирования стоимости дома имеет признак